

BioAgent | 目的からデモまで

何を実現したいか

生物由来の小さな判断モデルを、オンチェーン入力で動かし、経験から適応させる。その効果と計算資源を比較できるフレームワークをつくります。

使う人はAgentの開発者・研究者。入力の検証、モデルの出典、学習結果の追跡を再利用し、生物回路が役立つ条件を調べられることが価値です。

公開デモは、この順に説明する

1 | 開く

Sepoliaページをウォレットなしで開き、3個体を選んで観察。「判断する部分は実測7神経・19接続を使います。」

2 | 環境の出典を見る

「環境と餌の入力TX」を開き、初期環境TXを示す。「幅・高さ・危険エリアも、最初のTXに記録しました。」

3 | 刺激から行動へ

餌の元TXと行動を示す。「正の刺激TXが確定すると餌が1個増え、感覚入力へ変換して移動・休息を選びます。」

4 | 学習を確かめる

個体を選び「学習室へ」。「確認済み環境のコピーと経験からQ値を更新し、比較スコアが改善した候補だけ採用します。」

5 | 結果を読む

学習前／候補・採用／維持を確認。「同じ環境の再生での比較です。未知環境への効果は、別の比較実験で調べます。」

定期送信は毎時確認・最低1時間間隔。1分の説明では記録済みTXを使います。手動送信は所有者のみ。餌を食べ切ると休息し、自動補充しません。学習で改善しない結果も有効です。

3つの証拠を使い分ける

現在の公開ページ — Sepolia・7神経・3個体。TX入力と採餌・Q学習を体験。

提出動画 — Anvil・全166,700神経。前半は2個体の環境TXと学習比較、後半は4個体のAqua／V3決済。

独立した研究 — 合成採餌環境の対照比較。報酬は改善したが、生物回路の優位は未確認。

BioAgent | 発表・質疑応答

現行の共通Fly Labに対応。市場動画・独立研究の結果は明示して区別。

全神経動画を補足するとき（約30秒）

BioAgentは、生物由来の神経回路で行動を決め、入力・学習・取引結果を追える実験基盤です。動画の前半で全神経の環境TXと学習比較、後半で4個体のAqua提示とUniswap売買を示します。実取引と学習更新を確認しました。別の採餌実験では行動が改善しましたが、通常モデルへの優位は未確認です。そこまで比較できる基盤を作ったことが成果です。

166,700

神経／個体 × 4個体

27

新規決済：Aqua 2・V3 25

14回 × 4

学習更新。重み変化は3個体

価値と結果を答える

01 普通のAI Agentと何が違う？

生物の実測接続を、行動判断の特徴計算に使います。外から見れば同じ取引botです。差はモデルの由来と内部構造です。動力学・入力変換・行動変換は人工設計で、ハエの感情や意識を読み取ったものではありません。 R1・R2

02 BioAgentならではの利点は実証できた？

この課題で、生物由来であることの性能優位は未確認です。仮説は、固定された疎な回路と小さい学習部分で環境変化に対応できること。通常モデルでも学習・省メモリ化は可能です。同条件の対照と比較できることが現時点の成果です。 R3

03 Uniswap／1inchチームにどんな価値がある？

判断モデルを実際の決済まで接続して検証できる、参照実装です。Uniswapには、見積もり→実行／見送りを比較する実験の入口。Aquaには、同じ保有資金からの提示・撤回を学習モデルへ接続する例を提供します。利用者数、取引量、資本効率の増加は未測定です。 R2・R3

04 動画の市場場面では何を学習している？

確定した行動結果から、行動を選ぶreadoutの重みを更新します。実測の神経接続は固定です。今回14周期で全4個体の更新数が増え、3個体の重みが変わりました。報酬は提示の約定結果や目標保有比率への接近です。市場版はオンライン更新で、未使用データによる採用ゲートはありません。 R1・R2

05 動いただけでなく、改善効果はある？

別の7神経・人工採餌実験では、未使用環境で報酬が18.79→56.12へ改善しました。同予算の直接入力モデルも56.08で、生物優位は確認できませんでした。接触は平均1.25→0.10、終了時エネルギーは0.722→0.361に低下。5探索seed・60テスト環境／条件の結果で、動画の市場成績とは別です。 R3

06 LLMより低コスト・低消費電力？

定型判断の計算・更新を小さくし、電力・設備費・待ち時間を減らす可能性を調べています。収録時のPythonプロセス全体のpeak RSSIは443.1 MiB、最後の4個体分の神経計算は317.4 ms。電力は未測定で、比較優位の証拠ではありません。比較条件と想定反論は4ページ目にまとめています。 R1

実装・検証範囲を答える

07 ハエが取引先まで決めている？

神経モデルが行動を選び、通常コードが実行可能な見積もりを比較します。提示側はtight/wide/withdraw、売買側はhold/buy/sell。学習値に人工設計の基準値と探索を加えます。AquaかV3かはガス控除前の受取量で選択。独自FlyV3RouterとV3 coreを使用し、Trading API・Universal Router・v4 hooksは未使用です。 R2

08 IBioAgentを共通化するうまみは？

入力とモデルの意味を共通化し、検証・学習の処理を再利用することを目指します。Solidityは入力・権限、公開JavaScriptは判断・Q学習、Workersは取得検証。全神経版はNode.jsの制御とPythonの神経計算をJSON Linesで接続します。独立JSフレームワークとTypeScriptの共有型仕様は別です。構成はスライド付録へ。 R4・R8

09 何がオンチェーン？ 判断も検証できる？

箱庭の外部入力はすべてオンチェーンデータです。初期環境TXに危険エリアも記録。正の刺激TX確定ごとに餌が1個増え、食べると消えます。位置・身体・消費・学習はオフチェーンで、ブラウザー間では入力を共有します。receipt確認は最終確定や神経計算の正しさの証明ではありません。 R5・R6

10 PnLは利益？ 安全に自動売買できる？

テスト通貨の評価損益で、利益・運用安全性を実証したものではありません。需要は目標比率85%/15%の人工設定。PnLに交換費用は反映され、ガス代はETHで別表示です。提示側2個体は1つのEOAを共有します。数量・期限などの実行条件はありますが、監査済み製品ではありません。 R1・R2

11 審査員が公開URLで試すものも全神経？

公開ページはSepolia+7神経、提出動画はAnvil+全166,700神経です。公開版は3個体で、確認済み環境を再生するQ学習です。新旧方策の比較スコアが改善した時だけ採用します。新動画の前半は全神経2個体の採餌readout比較、後半は市場4個体のオンライン更新です。全神経も環境TXに対応しています。 R5

12 失敗から何を学んだ？ 次に何を測る？

報酬を上げるだけでは不十分で、副作用も採用条件に含める必要があります。採餌では休息を減らして報酬を上げ、体力が悪化しました。次はUniswapの固定ペア・同額見積もりで実行/見送りを比較し、未使用相場で手数料控除後の結果・失敗率・見送り率と計算資源を測ります。 R3

13 誰がTXを送る？ 審査員も送れる？

所有者EOAが署名し、Workersも同じ所有者鍵で定期送信します。鍵はCloudflare Secretに保管。毎時確認・最低1時間間隔でAgent #1に送信し、ガス・残高を制限します。観察と学習はウォレット不要。手動送信は所有者のみで、スマートウォレットではありません。餌はTX以外で自動補充しません。 R6

言い切る：実接続を使う・取引が成立・学習更新を確認。言い切らない：ハエの思考・生物優位・利益・LLMより安い・フル版と縮小版の同等性。

R1 Capture: receipts, model and learning deltas · R2 Shared market: actions, execution and limits · R3 Held-out experiment and negative results · R4 Framework: API, validation and restore · R5 Public Sepolia demo and transaction evidence · R6 Current environment-TX and scheduled sender evidence · R8 Architecture, languages and trust boundaries

AI Agent比較：期待する効果

対象は、数値入力から少数の行動を繰り返し選ぶ処理。汎用的な言語能力との比較ではありません。

狙いは、定型的な判断を小さい計算予算で継続することです。固定回路と小さなreadoutで、メモリー・計算時間・更新負荷を抑える可能性を調べています。低電力・低コスト・低遅延は期待する効果で、比較優位の実証はこれからです。

比較軸	期待する効果と理由（仮説）	実測・制約
電力・費用	CPU上の限られた計算で済めば、常時動作の電力や推論API費用を減らせる可能性。	節約先はAgent実行側。電力・費用は未測定で、ガス代・RPC等は別。
メモリー	固定の疎なグラフを個体間で共有し、個別状態と行動readoutを保持。	443.1 MiBは4個体を動かすPythonプロセスのpeak RSS。PC全体のRAMや組込機器での実績ではない。
反応速度	4stepの回路処理から行動へ進むため、毎回の文章生成や外部推論APIの往復を省ける。	収録14周期で神経処理は4個体合計304–349 ms。実行期限の保証ではない。
適応・更新	固定回路は維持し、readoutの180係数／個体だけを再適合できる。	柔軟性は対象課題の範囲内。小型AIも可能。LLMも文脈・指示から適応でき、重み更新が必須ではない。

14 LLMは256 GB必要だから、圧倒的に小さい？

必要量はモデル・精度・文脈で変わります。8Bモデルの重みだけならFP16で約16 GB、4bitで理論上約4 GB（十進）。KV cache等は別です。API利用側はモデルを載せません。同等の能力・仕事を揃えて比較します。S1・S2・S5

15 電気代は何分の一になる？

倍率は未測定です。RAMから消費電力は換算できません。同じ品質・判断数で機器全体のWとJ/判断を測ります。料金試算は平均W×稼働時間÷1,000×単価。API費・設備費・学習費も別に合算します。S3・R7

16 神経計算の時間で取引も終わる？

神経処理の時間と、取引成立までの時間は別です。4個体の神経計算＋特徴抽出は304–349 ms。RPC・ローカル取引等を含む周期は7.68–9.35秒、目標4秒を超える周期は延長。1個体の応答時間や公開チェーンの確定時間ではありません。R1・R7

17 普通の小型AIやreservoirでよいのでは？

有力な対照です。軽量化だけでは生物固有の価値になりません。固定回路＋学習readoutは既存研究にもあります。生物接続が時間的な判断へ役立つかを、ランダム回路・小型モデルと比較します。7神経の採餌実験では直接入力対照への優位は未確認です。R3・S4

18 何を揃えれば、公平な比較になる？

入力・行動・品質・頻度・測定範囲を揃えます。固定ルール、小型MLP/RNN、LLM、BioAgentを未使用データで比較。行動が使えるまでのp50/p95、失敗率、RAM、J/判断を測ります。LLMで計画し小型モデルで実行する分業も今後の候補です。R7

R7 Comparison rationale, measurements and protocol · S1 HF: weight quantization · S2 HF: KV cache and generation · S3 MLCommons: whole-system power · S4 ESN primary paper, § 2.1 · S5 HF: hosted inference

BioAgent | From purpose to demo

What we want to achieve

Build a framework for running biologically derived decision models on onchain inputs, adapting from experience, and comparing their effectiveness and resource use.

For agent developers and researchers: reuse input validation, model provenance and learning records to discover when biological circuits are useful.

Explain the public demo in this order

1 | Open

Open Sepolia without a wallet and select the three agents. “Decisions use seven measured neurons and 19 connections.”

2 | Trace the environment

Open “Environment and food input TXs” and its initial TX. “Dimensions and hazards were recorded in this transaction.”

3 | Follow stimulus to action

Show a food source TX and behavior. “One confirmed positive stimulus adds one food; the model uses encoded observations to choose movement or rest.”

4 | Inspect learning

Select an agent and press “Start learning”. “It updates Q-values using experience and a copy of the confirmed environment, adopting only a higher-scoring candidate.”

5 | Read the result

Show before/candidate and adopt/keep. “This compares replays of the same environment. We study unseen-world effects in a separate controlled experiment.”

The sender checks hourly, with at least one hour between sends. Use recorded TXs for a one-minute presentation. Manual writes require the owner. Once food is eaten, agents rest; there is no refill. No improvement is a valid result.

Use the three evidence tracks correctly

Current public page — Sepolia, 7 neurons, 3 agents: TX inputs, foraging and Q-learning.

Submitted video — Anvil, 166,700 neurons per agent: two-agent environment TX and learning comparison, then four-agent Aqua/V3 settlement.

Independent research — Synthetic foraging controls: reward improved, but a biological advantage was not established.

BioAgent | Presenter Q&A

Current shared Fly Lab. Recorded market results and independent research are labelled separately.

Optional: introduce the full-market video

BioAgent is an experimental platform that connects biologically derived circuits to traceable actions. The video first shows full-neuron environment TXs and learning comparison, then four agents making Aqua offers and Uniswap trades. We verified real local settlement and learning updates. A separate foraging experiment improved behavior, but did not outperform a matched non-biological model. Our contribution is a working platform for testing these possibilities and their limits.

166,700

neurons per agent × 4 agents

27

new settlements: 2 Aqua · 25 V3

14 × 4

learning updates; 3 agents changed weights

Explain the value and results

01 How is this different from an ordinary AI agent?

Measured biological connectivity participates in the action features. From the ecosystem, it still looks like a trading bot. The distinction is model provenance and internal structure. Dynamics, encoding and decoding are engineered; this is not a measurement of a fly's feelings or consciousness. [R1](#) · [R2](#)

02 Have you demonstrated a uniquely biological advantage?

Not on the task we tested. Our hypothesis is that a fixed sparse circuit plus a small learned readout could adapt efficiently. Ordinary models can also learn and use little memory. We built a way to compare these possibilities under matched conditions; superiority remains unproven. [R3](#)

03 What value do Uniswap and 1inch receive?

A reference implementation connecting alternative decision models to real settlement. For Uniswap: an entry point for comparing quote-based execute/hold policies. For Aqua: learned offer/withdraw decisions using shared self-custodied liquidity. User growth, routing volume and capital-efficiency gains are hypotheses, not measured outcomes. [R2](#) · [R3](#)

04 What learns in the market scenes?

The action readout updates from confirmed outcomes; neural connections stay fixed. All four agents received 14 outcome updates; 3 changed saved weights. Rewards reflect offer fills or progress toward target holdings. This full-market runtime updates online, without a held-out adoption gate. Updates alone do not establish a better trading policy. [R1](#) · [R2](#)

05 What improved beyond simply running the demo?

A separate seven-neuron foraging experiment improved held-out reward: 18.79 → 56.12. A matched direct-input learner scored 56.08, so biological superiority was not established. Mean contacts fell 1.25 → 0.10, but final energy fell 0.722 → 0.361. Five search seeds and 60 unseen worlds per profile; these are not market results. [R3](#)

06 Is it cheaper or more energy-efficient than an LLM?

We aim to reduce the compute and update costs of routine decisions, potentially saving energy, hardware and time. The shared Python process peaked at 443.1 MiB RSS; the last four-agent neural pass took 317.4 ms. Power is unmeasured; these are not comparative savings. Page 4 gives the hypotheses, counterarguments and comparison conditions. [R1](#)

Explain implementation and scope

07 Does the fly choose the trading venue?

The neural model selects an action; ordinary code compares executable quotes. Makers choose tight/wide/withdraw; traders hold/buy/sell, using learned scores plus engineered priors and exploration. Venue selection compares output before gas. We use V3 core and our FlyV3Router—not Trading API, Universal Router or v4 hooks. [R2](#)

08 What does the shared BioAgent interface provide?

A shared meaning for inputs and models, with reusable validation and learning components. Solidity handles inputs/authority; public JavaScript runs Q-learning, while Workers verifies inputs. Full mode uses Node.js control and Python computation over JSON Lines. The independent JS framework and proposed TypeScript types remain separate. See the architecture appendix. [R4](#) · [R8](#)

09 What is onchain, and is inference trustless?

All external inputs to the playground come from onchain data. The initial TX includes hazards; each confirmed positive stimulus adds one food, removed when eaten. Position, body, consumption and learning run offchain. Browsers share inputs, not body state. Receipt checks do not establish finality or correct neural computation. [R5](#) · [R6](#)

10 Does PnL prove profit or safe autonomous trading?

It is test-token mark-to-market accounting, not a profitability or safety result. Demand is manually set to 85%/15% target holdings. Swap costs affect PnL; ETH gas is shown separately. Two makers share one EOA. Execution has quantity/deadline checks, but this is not an audited trading product. [R1](#) · [R2](#)

11 Does the public demo run the full population?

The public demo is Sepolia + 7 neurons; the video is Anvil + 166,700 neurons per agent. The public page has three agents, Q-learning on confirmed-world replays, and a score-based adoption gate. The new video shows two full-foraging agents comparing readouts, then four market agents updating online. Both full foraging and public mode use environment TXs. Public Sepolia does not trade on Aqua/Uniswap. [R5](#)

12 What did failure teach you, and what comes next?

Reward improvement needs side-effect constraints and matched controls. Foraging learned to rest less, raising reward while depleting energy. Next: compare execute/hold policies on identical Uniswap pair/size quotes, using unseen market regimes, fee-adjusted outcomes, failure/skip rates and resource measurements. [R3](#)

13 Who sends TXs? Can judges send them?

The owner EOA signs; Workers uses the same owner key for scheduled sends. The key stays in a Cloudflare Secret. Hourly checks send to Agent #1 at least an hour apart, subject to gas and balance limits. Viewing and learning need no wallet; manual writes require the owner. This is not a smart wallet. Food never refills without a TX. [R6](#)

Say: measured connectivity, successful settlement, observed learning updates. Do not claim: fly thoughts, biological superiority, profit, lower LLM cost, or equivalence of full and reduced runtimes.

[R1](#) Capture: receipts, model and learning deltas · [R2](#) Shared market: actions, execution and limits · [R3](#) Held-out experiment and negative results · [R4](#) Framework: API, validation and restore · [R5](#) Public Sepolia demo and transaction evidence · [R6](#) Current environment-TX and scheduled sender evidence · [R8](#) Architecture, languages and trust boundaries

AI agent comparison: expected benefits

Scope: repeated choices among a few actions from numeric inputs, not equivalent general language ability.

We aim to keep routine decisions running within a small compute budget. A fixed circuit and a small readout may reduce memory, processing and update costs. Lower energy use, cost and latency are hypotheses; a matched comparison must establish the benefit.

Dimension	Expected benefit and mechanism	Evidence and limits
Energy / cost	Bounded CPU work could lower always-on energy use or repeated inference-API charges.	Savings would accrue to agent operators. Power/cost are unmeasured; gas and RPC costs remain.
Memory	Share one fixed sparse graph across individuals; keep separate states and readouts.	443.1 MiB is peak RSS of the four-agent Python process, not whole-system RAM or proof of microcontroller deployment.
Latency	Four circuit steps can lead to an action without generating text or calling an external inference API.	Four-agent neural processing: 304–349 ms in 14 recorded cycles. This is not a real-time guarantee.
Adaptation	Refit only 180 readout coefficients per agent; keep the circuit fixed.	Task-specific flexibility. Small conventional models can do this too; LLMs can adapt via context without retraining.

14 Does every LLM need 256 GB?

No: model size, precision and context determine memory. For an 8B model, weights alone are about 16 GB at FP16 or an ideal 4 GB at 4-bit (decimal). KV cache and overhead are extra. API clients do not host those weights. Compare equivalent tasks. [S1](#) · [S2](#) · [S5](#)

15 How much electricity does it save?

We have no measured savings ratio; RAM does not determine watts. Measure system power and joules per decision at matched quality and workload. Electricity cost = average W × operating hours / 1,000 × tariff. Add API, hardware and training costs separately. [S3](#) · [R7](#)

16 Does neural processing time include settlement?

Neural processing and settlement latency are different. Four-agent neural computation plus features took 304–349 ms; cycles including local transactions/RPC took 7.68–9.35 s. The 4 s target extends for slower cycles. These are neither single-agent response times nor public-chain finality. [R1](#) · [R7](#)

17 Why not a small AI model or a reservoir?

They are essential controls; efficiency alone is not uniquely biological. Fixed circuits with learned readouts already exist. We must compare biological wiring against random circuits and small models for temporal decisions. The seven-neuron foraging experiment did not establish an advantage over direct inputs. [R3](#) · [S4](#)

18 What makes the comparison fair?

Match inputs, actions, quality, request rate and measurement scope. Compare rules, small MLP/RNNs, LLMs and BioAgent on unseen data. Measure usable-action p50/p95, failures, RAM and joules/decision. LLM planning plus a small action controller is another future option. [R7](#)

[R7](#) Comparison rationale, measurements and protocol · [S1](#) HF: weight quantization · [S2](#) HF: KV cache and generation · [S3](#) MLCommons: whole-system power · [S4](#) ESN primary paper, § 2.1 · [S5](#) HF: hosted inference